Анализ сети авиасообщения Европы

2. Причина выбора темы и источники данных

- Почему **самолеты**? – легко и понятно создать граф.
- Почему **Европа**? – доступность данных, достаточно замкнутая на себя сеть.

Источники данных:

- **Open airports csv dataset**, site – получили аэропорта Европы
- **OpenSky network**, site – очень грязные данные по перелетам, но бесплатно и по API 😊
- Дополнительная информация: Eurostat, AviationStack etc
- Того что нет в датасетах: chatgpt deep research / googling

3. Как создавался граф.

- **Вершины**: аэропорта объединены в **города**.
  - Например, в **Лондоне их 7**.
- Выбрана одна неделя 16–22.02.2026, собраны полеты во всем мире, почищены от nan, “смэтчины” с нужными нам аэропотрами.
  - Связь: **город** → **коды аэропортов** ← **полеты**.
- Полеты сагрегированы в **ребра** – авиасообщение между городами.
  - Вес ребра отражает **интенсивность сообщения**.
- Граф **направленный и взвешенный**.

4. Проблема направленного графа.

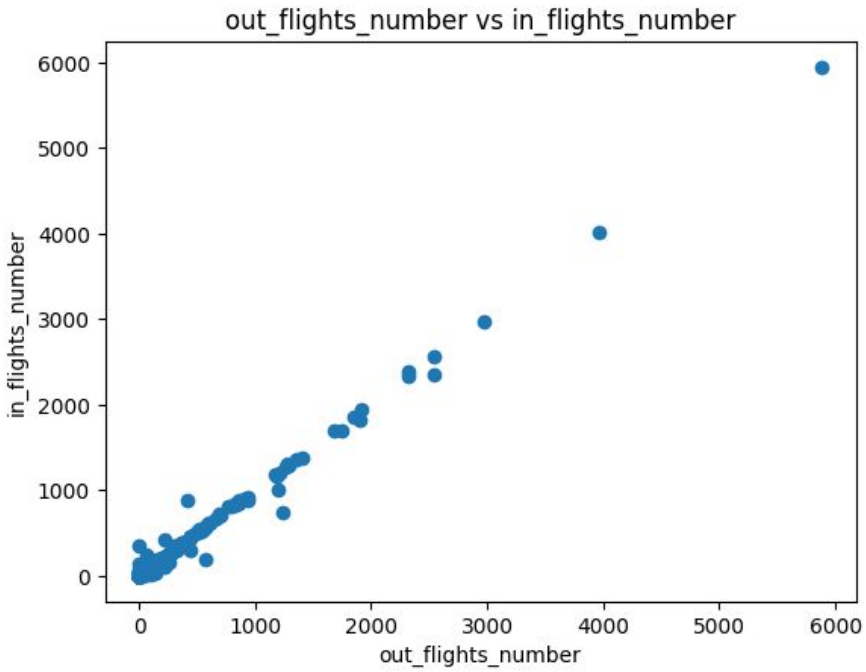

Неаполь – 137 in and 2 out.

- Причина бесплатные данные 😊:
  - шум, неполные наблюдения и **артефакты источника** (self-loops, 1km flights etc)
- Решение – **перевод в ненаправленный**.
  - дополнительно удалялись **выбросы и слабые связи**.
  - pruning, который пошел не по плану

5. Часть атрибутов вершин и ребер

Вершины:

- Id
- Name
- Country code / region code
- Latitude / longitude
- Airports / airports count
- **Edges count** (= degree)
- Node type
- **Node degree** (= weighted)

Ребра:

- Id1
- Id2
- Weight – интенсивность
- Distance

EU flights graph colored by node_type

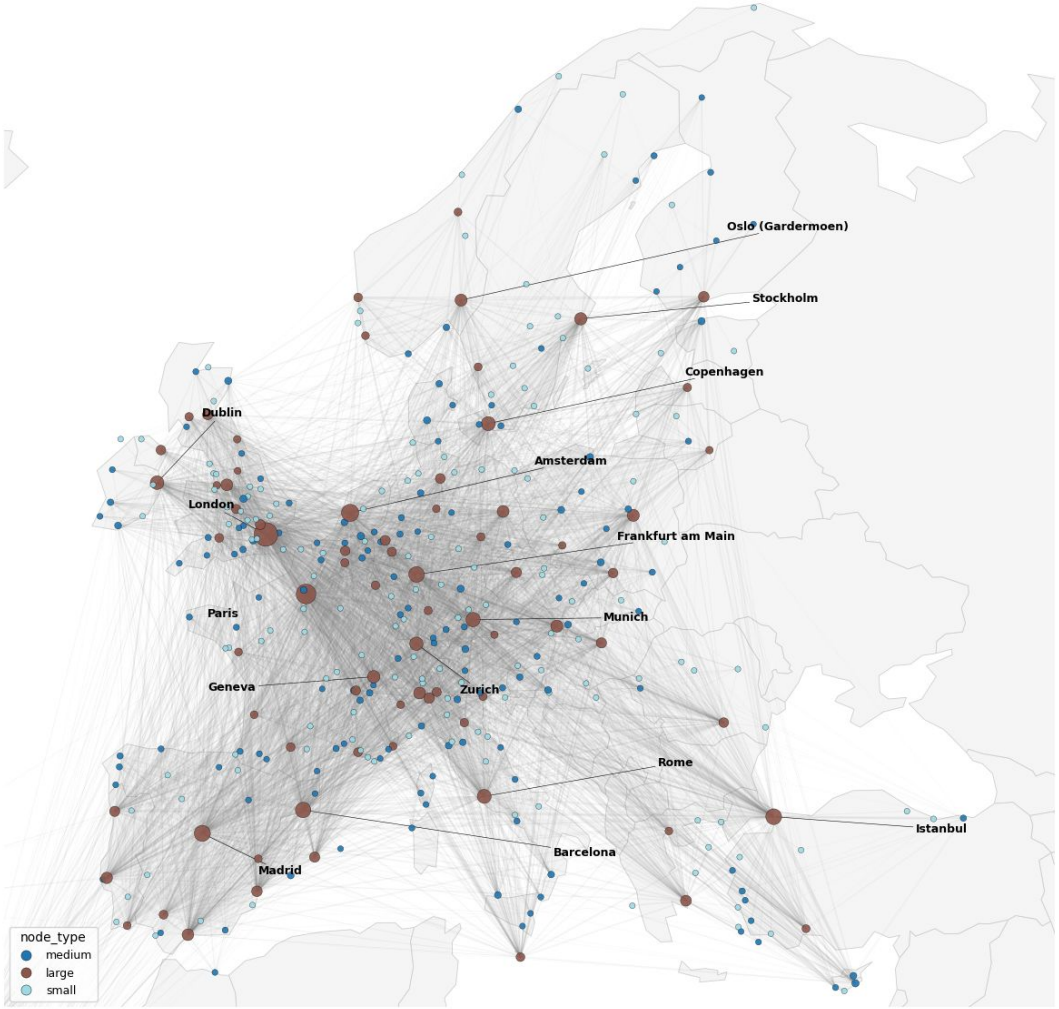

6.1. Визуализация

Весь граф. Hue – node type: small, medium, large

Flights graph: FR + GB + DE + IE + Benelux, colored by country

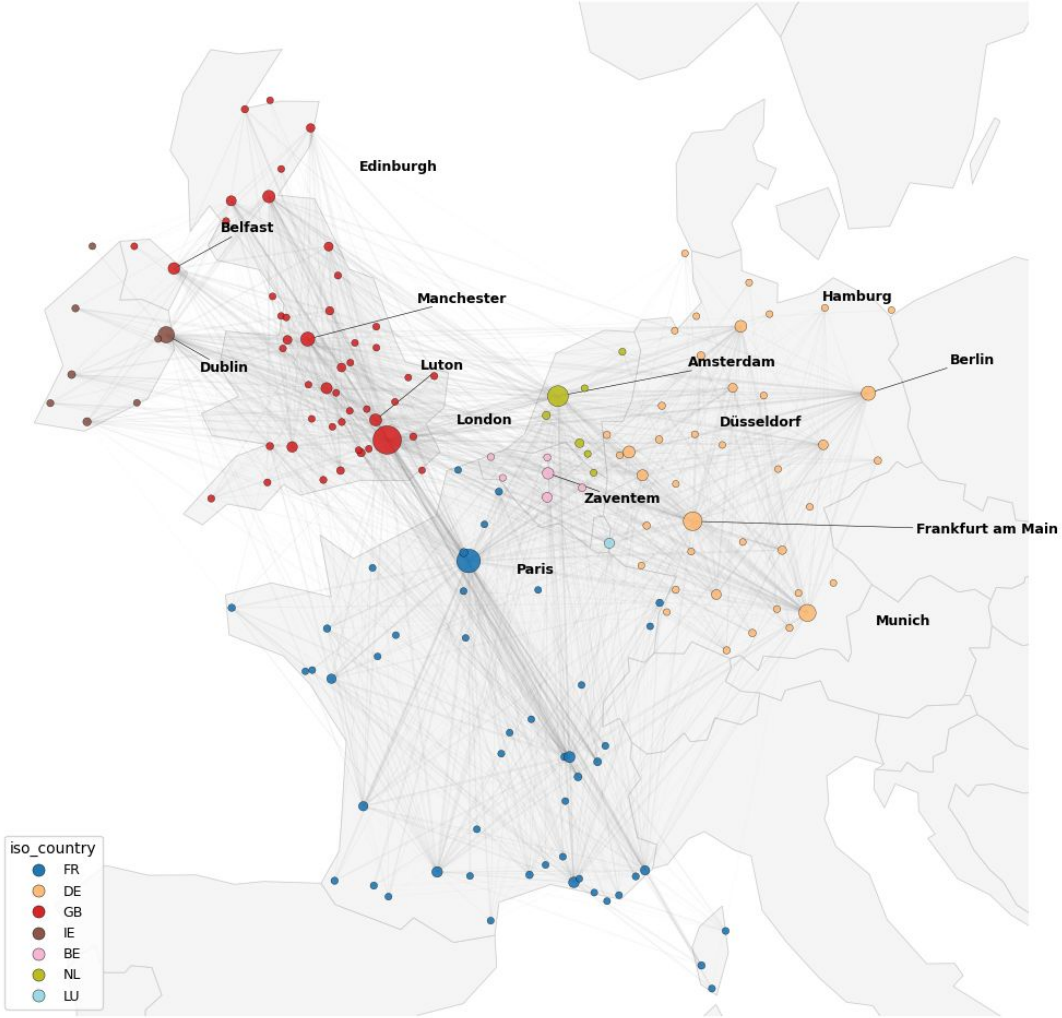

6.2. Визуализация

Несколько стран: Великобритания, Франция, Германия, Бенелюкс, Ирлания. Hue – страна.

6.3. Визуализация страны Юга. Hue – node type

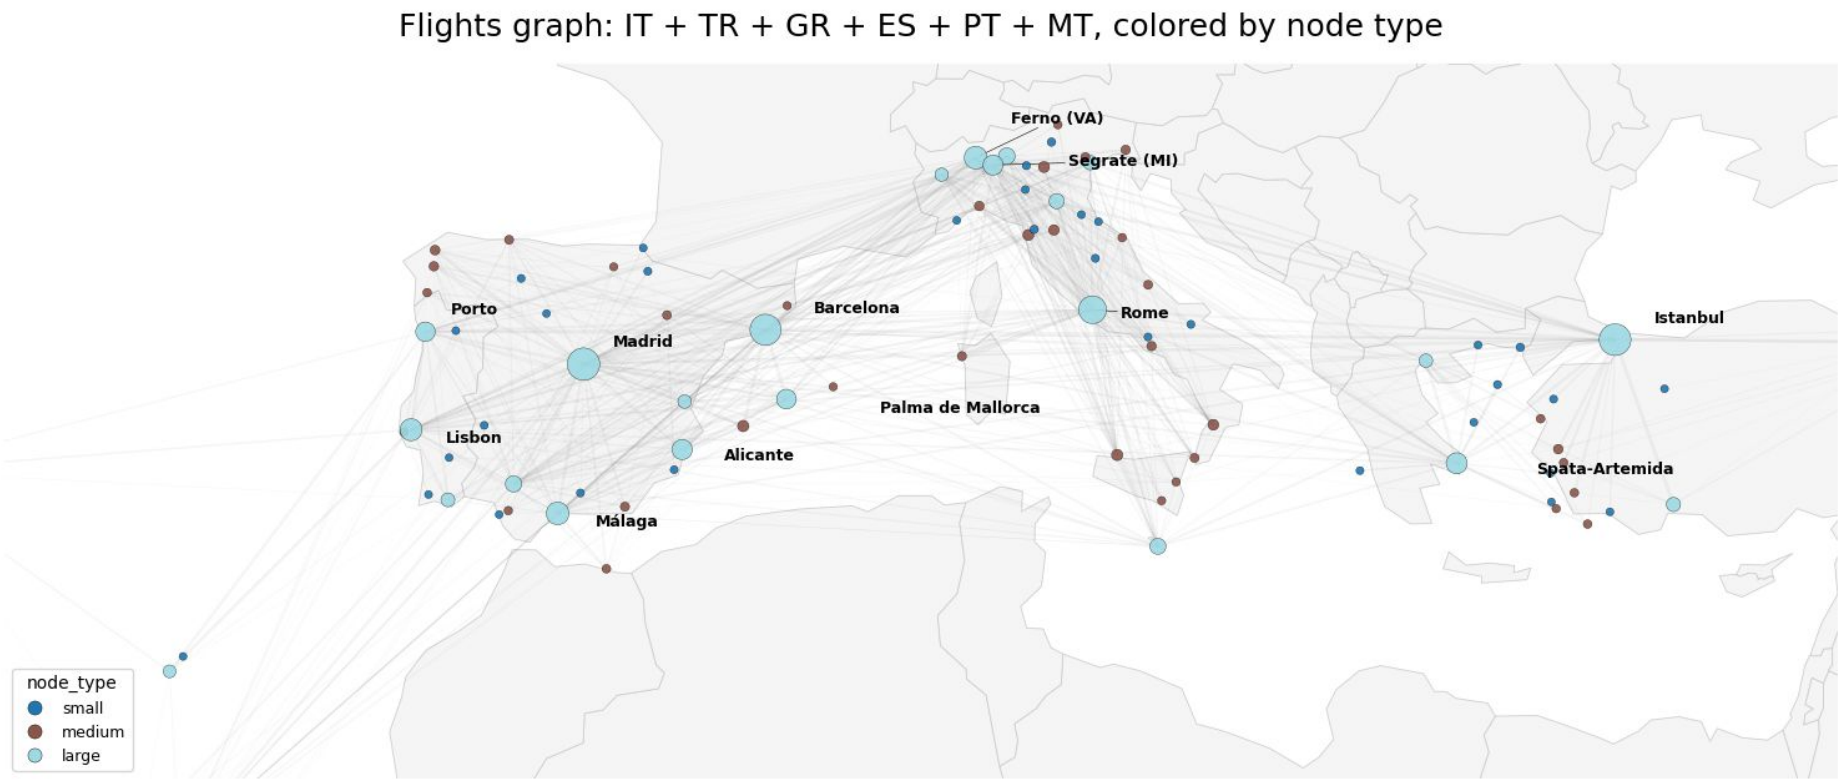

7.1 EDA1: Анализ вершин

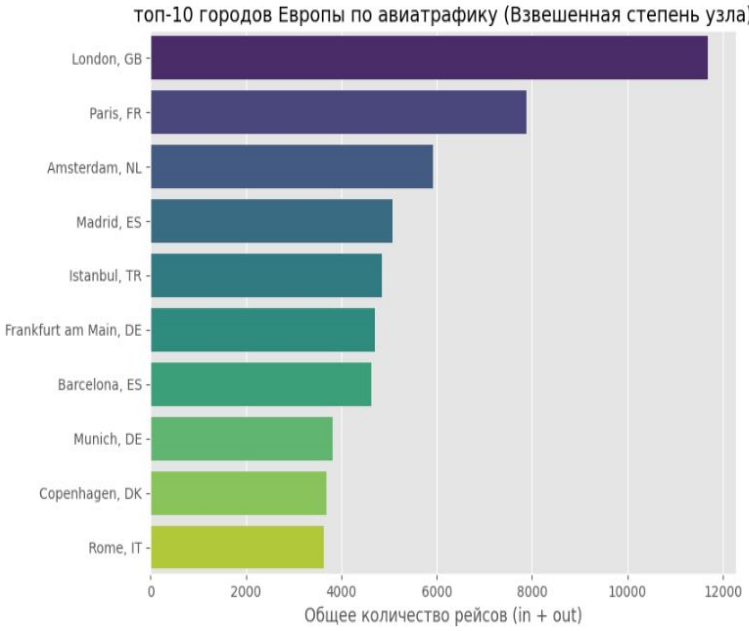

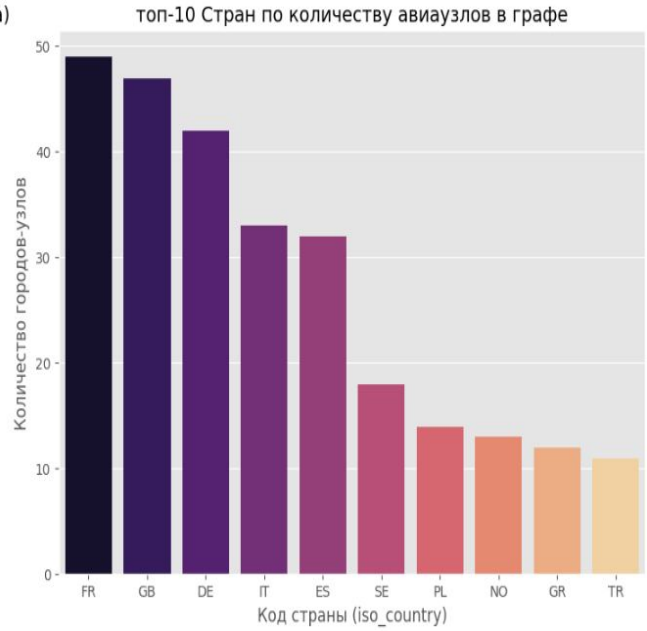

7.2 EDA2: Анализ ребер(маршрутов)

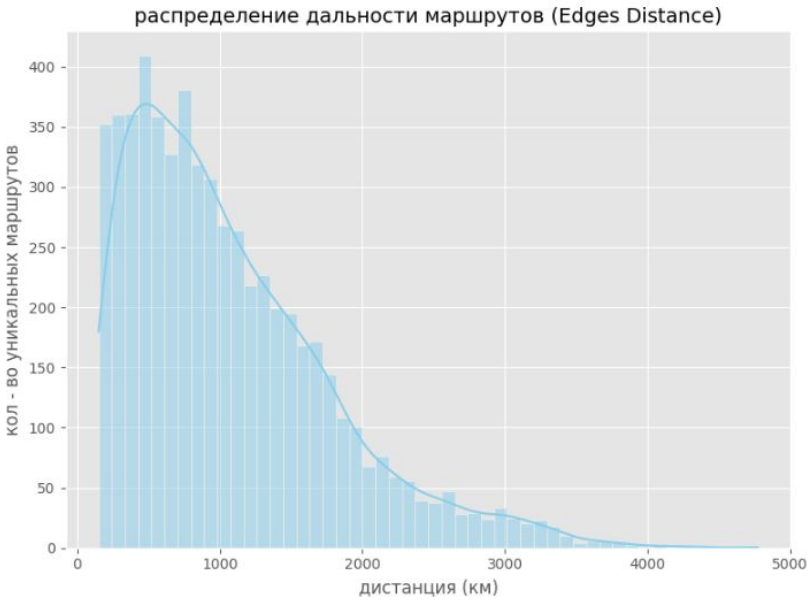

Гравитационная модель (Gravity Model) - поток пассажиров (в нашем случае weight — количество рейсов) прямо пропорционален размеру городов и обратно пропорционален квадрату расстояния между ними

8. Базовые характеристики

а) **Размер и Плотность** (Size and Density). Это фундамент нашей сети, показывающий её масштаб:

- Количество узлов = 371
- Количество ребер = 5862
- Средняя степень (2m / n) = 31.6 рейсов на город

б) **Дистанции** (Distances)

- Диаметр(“Какое максимальное число пересадок потребуется, чтобы пролететь Европу из конца в конец при самом неудачном раскладе”) = 4 пересадки
- Радиус(самый короткий из всех кратчайших путей) = 3 пересадки
- Средняя длина пути = 2.24 пересадки => наличие свойства 'тесного мира'

в) **Кластеризаци**. Измеряем тенденцию городов образовывать плотные треугольники маршрутов

- Глобальная транзитивность = 0.4035
- Средний коэффициент кластеризации = 0.4886

=> авиалинии не строятся случайным образом. Маршруты образуют плотные региональные треугольники (соседи активно летают друг к другу)

9.1. Анализ распределения степеней

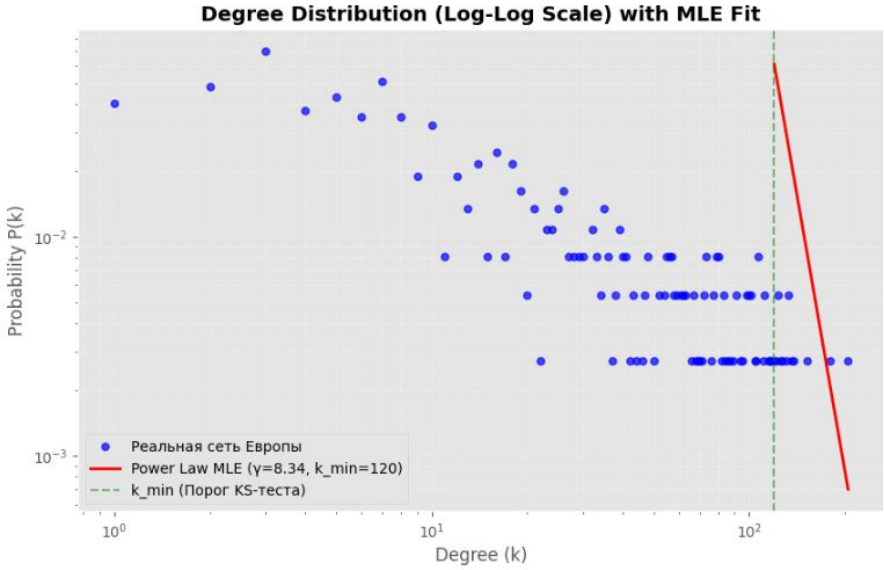

1. **Моменты распределения степеней**
   - средняя степень <k>: 31.60
   - второй момент <k^2>: 2301.34
   - реальная дисперсия: 1302.71 (Для случайной сети должно быть ~5.62)
   - вывод: реальная дисперсия в 231.7 раз больше случайной => сеть Безмасштабная (Scale-Free)

2. **Поиск kmax** (Ожидаемый размер максимального хаба)
   - Оптимальный порог отсечения шума (k_min): 120
   - Точный гиперпараметр Power Law (Gamma): 8.3409
   - Дистанция Колмогорова-Смирнова (D): 0.0919

3. **Анализ максимального хаба k_max**
   - реальный размер крупнейшего хаба: 205 связей
   - теоретический предел, если бы сеть была случайной: ~6 связей
   - теоретический предел по Степенному закону: ~269 связей

9.2 Анализ распределения степеней - выводы

=> Европейская авиасеть фундаментально отличается от случайного распределения Пуассона => наличие свойства Scale-Free (Безмасштабности).

*Для точной оценки гиперпараметров мы применили Метод Максимального Правдоподобия (MLE) в связке с тестом Колмогорова-Смирнова. Алгоритм определил оптимальный порог k_min, отсек шум и вычислил истинную Гамму (γ).

Инсайт 1: Почему алгоритм отрезал 95% графа (k_min = 120)?

Алгоритм, пытаясь минимизировать ошибку (дистанцию D), был вынужден убежать от этого шума в самый конец хвоста, где остались только единичные супер-хабы, и данные стали похожи на непрерывные.

Инсайт 2: Аномальная Гамма (γ = 8.34) и Эффект конечного размера

γ = 8.34 (красная линия падает почти вертикально) - это отражение так называемого Эффекта конечного размера (Finite-size effect / Structural cutoff).

Огромная Гамма означает, что вероятность появления хаба, который будет еще больше текущего максимума, стремится к абсолютному нулю.

У реального аэропорта есть жесткий физический предел: количество взлетно-посадочных полос, пропускная способность терминалов и слоты времени. Аэропорт просто не может принимать бесконечное число рейсов.

9.3 Сравнение с моделями (ER, BA, WS)

Главная цель: Понять скрытый алгоритм и механизм эволюции, по которому в реальности строилась европейская авиасеть.

1. Модель Эрдёша-Реньи (ER) — Случайная сеть

Берем N городов и для каждой пары создаем связь с вероятностью p. Модель G(N, p)

=> ее кластеризация (C) почти равна нулю. Это доказывает полное отсутствие случайности в построении авиамаршрутов.

2. Модель Барабаши-Альберта (BA - Безмасштабная сеть)

Каждый новый аэропорт присоединяется к старым по правилу Предпочтительного присоединения (Preferential Attachment)

=> Отлично объясняет появление супер-хабов (Лондон, Франкфурт) через механизм преференциального присоединения. Однако ее итоговая кластеризация слишком низкая по сравнению с реальной сетью.

3. Модель Уоттса-Строгаца (WS - Тесный мир)

Мы берем кольцо (где все соседи соединены друг с другом локально) и с крошечной вероятностью p перекидываем часть связей на другой конец графа.

=> **Локальное кольцо дает огромную кластеризацию C (региональные авиарейсы), а перекинутые связи работают как трансконтинентальные лоукостеры, резко сжимая длину пути L**.

3. Сравнение метрик

	Модель (Network Model)	Кластеризация (C)	Средний путь (L)	Механизм генерации
0	Real Network (Europe Air)	0.4886	2.2363	География + Экономика
1	Erdős-Rényi (ER)	0.0882	1.9734	Случайность (Монетка)
2	Barabási-Albert (BA)	0.1569	2.0134	Богатый богатеет (Хабы)
3	Watts-Strogatz (WS)	0.5363	2.3686	Кольцо + Шорткаты

В реальности наша сеть является гибридом. Она *имеет высокую кластеризацию, как у модели Уоттса-Строгаца (WS)*, за счет плотных региональных рейсов, но при этом <u>обладает ультра-коротким средним путем (L) за счет доминирования хабов из модели BA</u>

9.4 Расчет метрик центральности, PAGERANK И HITS

1. Лондон занимает первое место по всем без исключения метрикам. Он имеет прямые связи с 55% сети (Degree 0.554), до него быстрее всего добраться (Closeness 0.690), и он же контролирует максимальную долю транзита (Betweenness 0.094)
2. Лондон, Париж, Амстердам - формируют главный географический и экономический треугольник Европы, через который стягиваются и перераспределяются основные потоки пассажиров
3. Стамбул - Пограничный брокер
4. PageRank: на ненаправленном графе PageRank становится практически идентичен Центральности по степени
5. HITS: в ненаправленной сети оценка Хабовости всегда будет в точности равна оценке Авторитетности (h = a)

ТОП-10 главных узлов сети (отсортировано по PageRank):

	Degree	Closeness	Betweenness	Eigenvector	PageRank	HITS_Hubs	HITS_Authorities
London, GB	0.554054	0.690299	0.094973	0.162600	0.057570	0.059208	0.059208
Paris, FR	0.486486	0.657194	0.072899	0.152404	0.041237	0.041126	0.041126
Amsterdam, NL	0.410811	0.625000	0.035460	0.144904	0.029345	0.033641	0.033641
Madrid, ES	0.367568	0.604575	0.027624	0.132395	0.025840	0.031143	0.031143
Istanbul, TR	0.310811	0.584518	0.033622	0.120890	0.025310	0.024104	0.024104
Barcelona, ES	0.354054	0.602606	0.024673	0.132464	0.022556	0.028968	0.028968
Frankfurt am Main, DE	0.343243	0.595813	0.013457	0.131528	0.022504	0.026464	0.026464
Munich, DE	0.329730	0.589172	0.018139	0.125641	0.019095	0.022349	0.022349
Rome, IT	0.359459	0.604575	0.020190	0.134230	0.018274	0.022423	0.022423
Copenhagen, DK	0.264865	0.565749	0.010018	0.111880	0.017956	0.020447	0.020447

Что еще можно узнать о графе?

10.1.1. Возвращение, к графу. **Node type** attribute.

Наш датасет с аэропортами содержит **airport type → node multi class classification.**

- **Левые хвосты** выглядят не очень.
- Причина – другие **бесплатные** данные 😊

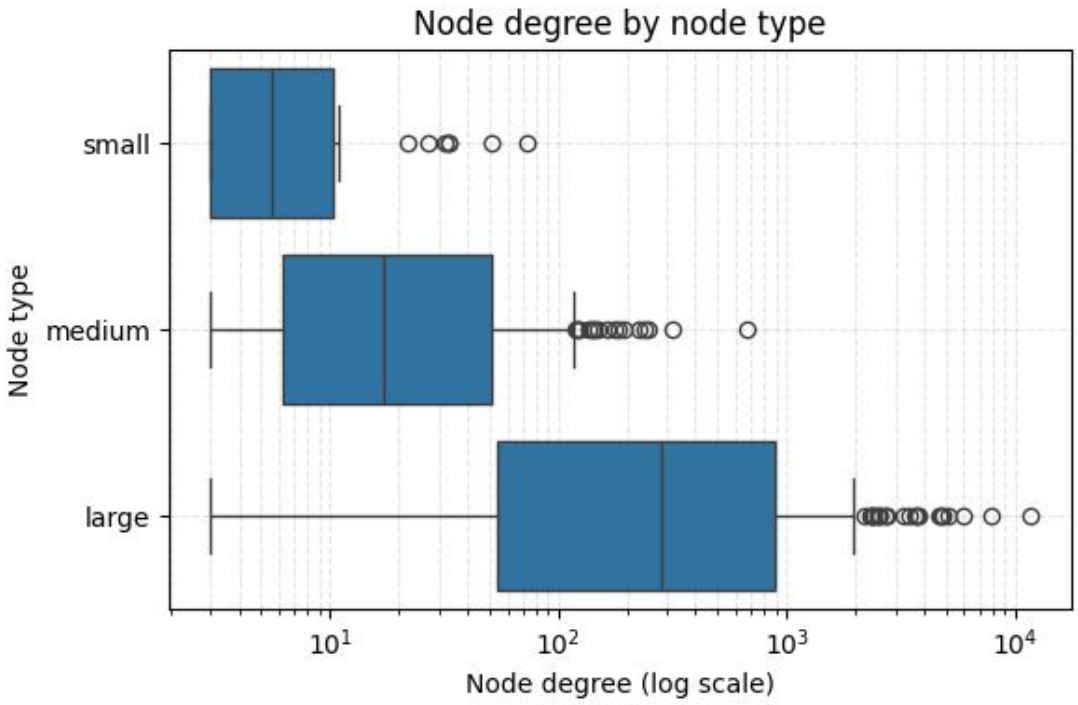

10.1.1. Возвращение, к графу. **Node type** attribute.

Chat gpt deep research и дочистка руками. Позволило удалить выбросы: Варна.

Было

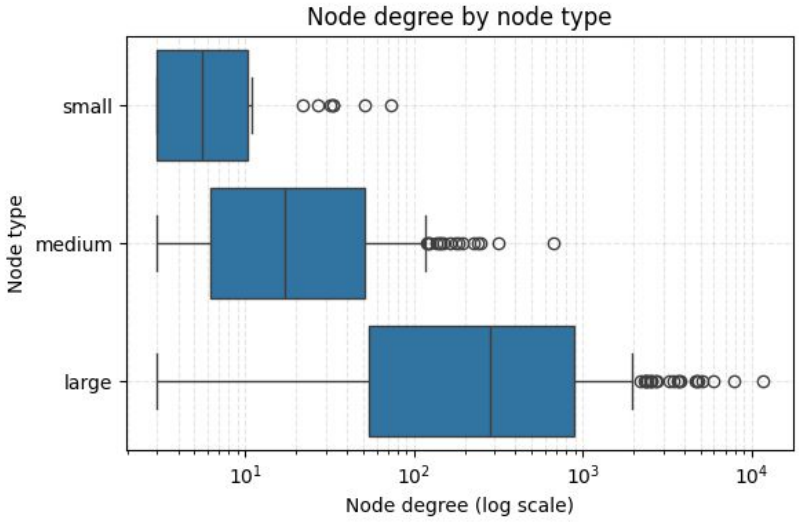

Стало

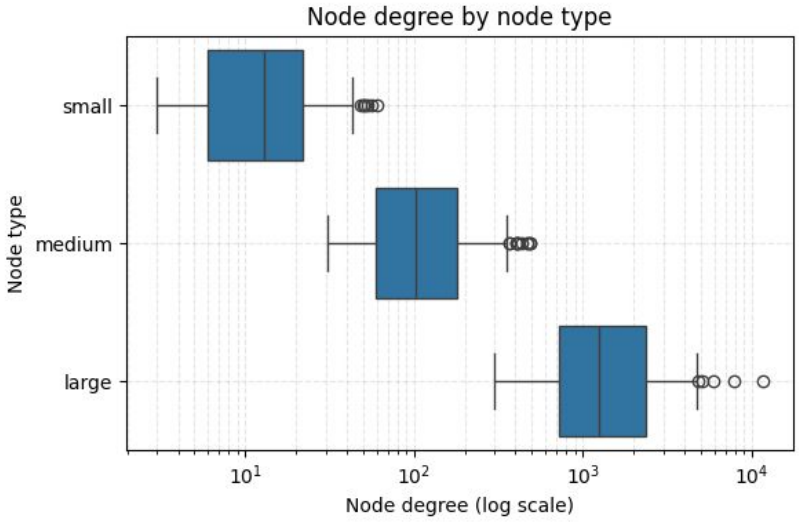

10.2. Возвращение, к графу. **Nut3** 🤗 **code** attribute.

*NUTS3 – Nomenclature of territorial units for statistics.

- Node → nuts3 code → pps per capita. **Regression**.

Источники:

- PPS – eurostat database
- Node-code matching: google search → chat gpt → json

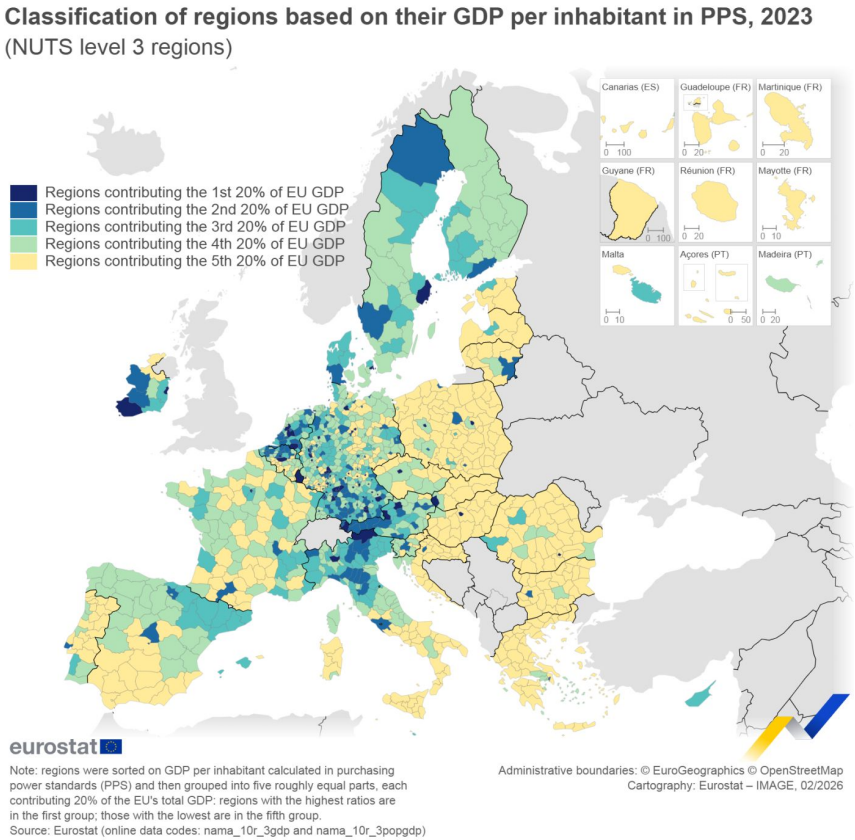

10.3. Возвращение, к графу. **Edges embeddings** attribute.

- У каждого полета есть 2 кода: callsign и icao.
  - Callsign → company
  - Icao → bad free 😊 databases → plane type
- Chat gpt + ручная дочистка можно сагрегировать и получить **эмбединги для ребер**.
- Vectors of the size = 21:
  - Lufthansa_group
  - Air_france_klm_group
  - Cargo
  - …
  - Narrowbody_boeing
  - Business_jet
  - …

in_grouping	icao
good	40922
nan	6721
not aggregated	2473

in_grouping_callsign	icao
good	42451
not aggregated	7665

ПС это **новые графы**!!!

11.1. Node assortativity

Hub-and-spoke, не “хабы соединяются с хабами”:

- degree assortativity = -0.146

По типу узлов сильной “сегрегации” тоже нет:

- assortativity по node type = -0.024

	type_1	type_2	count
0	large	medium	2372
2	large	large	1930
3	large	small	579
1	medium	medium	569
5	medium	small	330
4	small	small	82

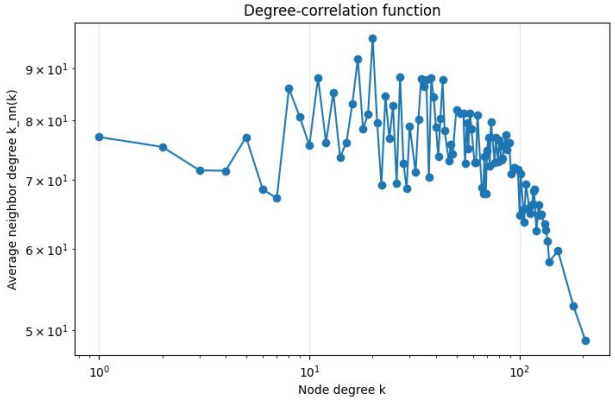

11.2. Node similarity

Jaccard similarity (= 100 degree):

- = 1 for nodes with 1 degree

- Bodrum & Selçuk (TR) = 0.714
- Manchester & Edinburgh (GB) = 0.6065
- Alicante & Málaga (ES) = 0.582

Это города из одной страны = одни интересы, одни направления полетов.

EU flights graph colored by Louvain communities

12. Communities using Louvain

1. France + Spain - 105 nodes
2. Germany + Turkey - 81 nodes
3. UK + others - 67 nodes
4. Italy + Eastern Europe - 66 nodes
5. Northern Europe - 48 nodes
6. NATO military / outlier - 4 nodes

Получилось неплохо 😇

13.1. ML. Классификация node type (для вершин)

- Проблема: **диспропорция класса large** → F1
- Решение – успех!
  - Dummy: accuracy ~ 0.41, macro F1 ~ 0.19
  - Logistic Regression: accuracy ~ 0.81, macro F1 ~ 0.82
  - **Random Forest**: accuracy ~ 0.93, **macro F1 ~ 0.94**

Random forest feature importance:

- Weighted_degree = 0.365 🤗
- Pagerank = 0.2228
- Closeness = 0.1292

13.2. ML. Регрессия по pps per capita (для вершин)

- Проблема: the same code for different nodes – {1: 157, 2: 25, 3: 9, 4: 2, 5: 1} → немного сложная
- А еще **много много много признаков**… не успех, R2 < 0 (GradientBoosting -0.210).
  - “Своя разработка”: Target Encoding based on Louvain communities.

Лучший вариант: Ridge on “C_plus_comm_mean” feature set, R2 = 0.262

Feature importance for GradientBoosting (R2 = 0.1495), stable. Повод подумать:

- Closeness = 0.290
- Longitude = 0.1743

13.3.1 Embeddings: message passing на минималках

- Вершины агрегируют:
  - Наши **21-числовые embedings с ребер**, собранные за один проход.
  - Дополнительная **информация, вычисленная из них** – entropy, mean, std
  - Дополнительная **информация из вершин**: share_long_routes_1000km
- **= 74-числовые эмбединги**

13.3.2 Embeddings: магия PCA на 2 компоненты

Explained variance ratio:

- [0.16, 0.12]

Total explained variance:

- 0.283

Текстом выделены **топ-20 аэропортов** по трафику.

Они **все в одном месте**!

Счастье 🤗

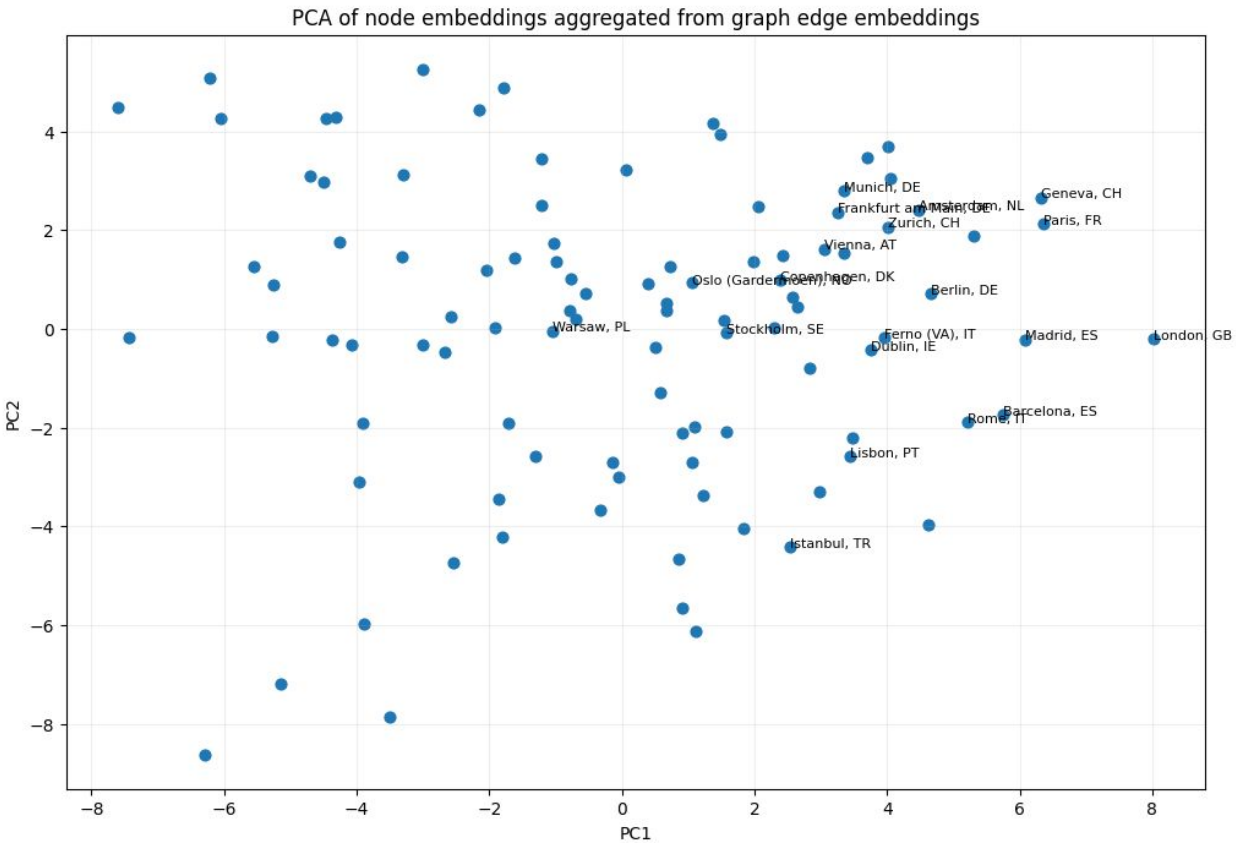

13.3.3 Embeddings: k means на 5 кластеров

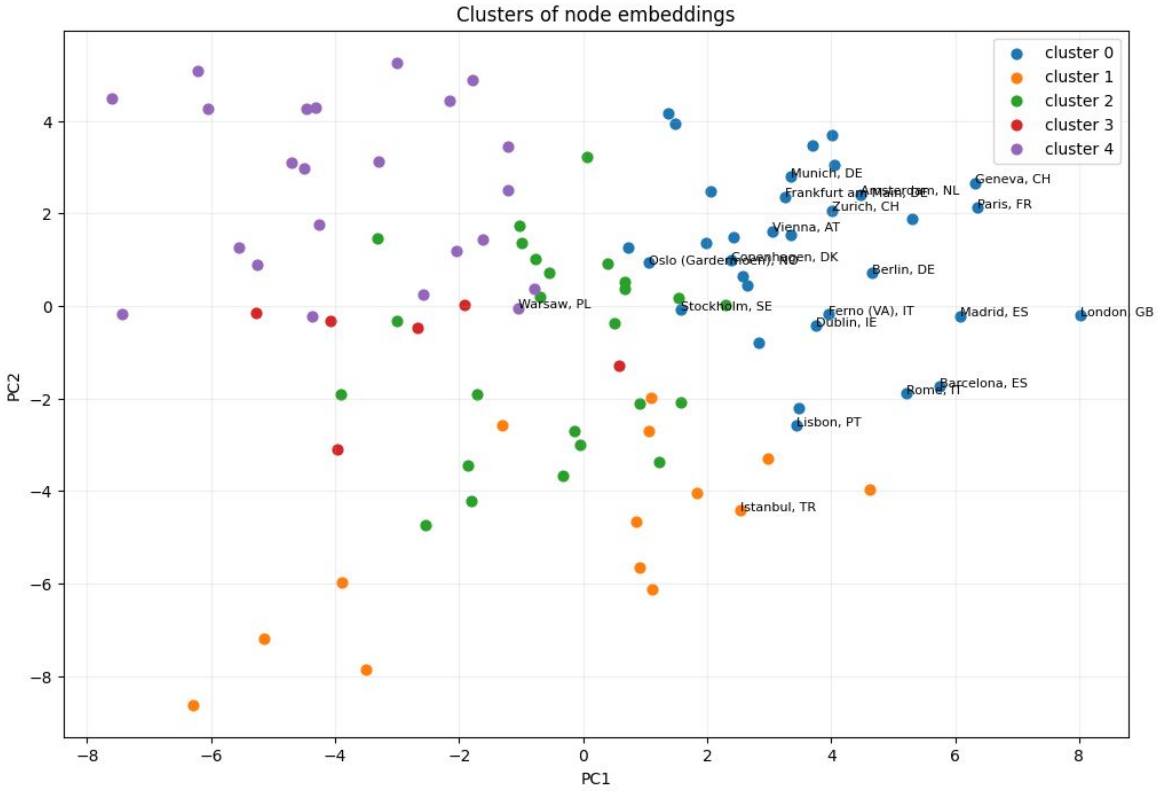

13.3.4 Embeddings: cosine similarity

semantic_cluster	n_nodes	avg_weighted_degree	avg_mean_distance	avg_long_routes	avg_airline_entropy	avg_aircraft_entropy
0	33	**2340.63**	886.81	0.324	**1.7**	0.94
1	14	950.5	1421.54	0.73	1.3	0.74
2	25	485.88	755.85	0.23	1.14	0.86
4	23	412.41	629.61	0.1597	0.97	0.90
3	6	326	758.56	0.26	1	0.92

Cluster 0: has the largest average weighted degree and relatively high entropy. This looks like a group of major, diverse hubs. Это не Louvain!!!

13.3.5 Embeddings: cosine similarity for Amsterdam. Улучшенная “версия” меры Жаккара

- Paris, FR 0.709999
- London, GB 0.520433
- Toulouse/Blagnac, FR 0.469167
- Marignane, Bouches-du-Rhône, FR 0.416169
- Geneva, CH 0.403383

Неплохо получилось!

13.3.6 Embeddings: profile for a city

City: Amsterdam, NL
- **degree**: 74
- **weighted degree**: 5317.0
- **mean route distance**: 850.1 km
- **share of long routes** >1000 km: 0.285
- **cluster**: 0
- **dominant airline group**: pct_air_france_klm_group
- **top airline groups**:
  pct_air_france_klm_group: 0.597
  pct_easyjet_group: 0.103
  pct_other_low_cost_leisure: 0.072
- **dominant aircraft group**: pct_narrowbody_airbus
- **top aircraft groups**:
  pct_narrowbody_airbus: 0.385
  pct_regional: 0.298
  pct_narrowbody_boeing: 0.279
- **nearest neighbors**:
  Paris, FR: 0.710
  London, GB: 0.520
  Toulouse/Blagnac, FR: 0.469
  Marignane, Bouches-du-Rhône, FR: 0.416
  Geneva, CH: 0.403

13.3.7 “Business value” – GPT node guesser, link 😇

- Я **загадал Анталью, Турция**. GPT задал уточняющие вопросы:
  - Is the city on an island? — NO
  - Is the city in Greece? — NO

Final guess: **Antalya, TR**:

- Airline mix is **overwhelmingly turkish_and_south_east_legacy** (0.935), which strongly points to a Turkish or nearby Southeast European pattern.
- The nearest neighbors are Thessaloniki, Istanbul, Spata-Artemida, and Larnaca, which place it in an **East Mediterranean / Aegean semantic neighborhood**.
- It is not on **an island and not in Greece**, which removes Larnaca, Spata-Artemida, and Thessaloniki, leaving Antalya as the best fit over Istanbul.

Alternative **guesses**:
- Istanbul, TR
- Velika Gorica, HR